Курс kiev-clrs – Лекция 8. Универсальное хэширование. Идеальное хэширование

Олег Смирнов

23 мая 2009 г.

Содержание

| 1 | Цель лекции | 2 |
|---|--------------------------------------|---|
| 2 | Универсальное хэширование | 2 |
| 3 | Конструкция универсального множества | 3 |
| 4 | Идеальное хэширование | 5 |
| | 4.1 Анализ размера таблицы | 6 |

1 Цель лекции

- Свойства и способ построения универсальных хэш-функций
- Свойства идеального хэширования

2 Универсальное хэширование

Фундаментальная проблема хэширования заключается в том, что при любом выборе хэш-функции существует некоторый набор ключей, которые хэшируются в один и тот же слот таблицы.

Например, при разработке компилятора который использует хэштаблицу для хранения имен переменных, возможно подготовить такой тестовой файл, что все имена попадут в один слот таблицы и это существенно замедлит компиляцию.

Идея: разработать метод выбора хэш-функции случайным образом, независимо от ключей. В этом случае будет невозможно использовать заранее заготовленный набор "плохих" ключей.

Определение: Пусть U — множество всех ключей и пусть H — конечное множество хэш-функций $f:U\to\{0,1,\ldots,m-1\}$. Множество H называется универсальным, если для любых $x,y\in U$, при $x\neq y$: $|\{h\in H:h(x)=h(y)\}|=|H|/m$. Т.е. шанс коллизии между ключами x и y будет 1/m (шанс попасть в розовую область на рисунке) для любого случайного выбора h из H.




Рис. 1: Универсальное хэширование

Теорема: Пусть h — хэш-функция выбранная равновероятно из универсального множества H. Пусть функция h используется для хэширования n ключей в m слотов таблицы T. Тогда для произвольного ключа x выполняется E[#коллизии с $x] < n/m = \alpha$.

Т.е. функции в универсальном множестве ведут себя в точности таким образом, как нам нужно.

Пусть C_x – случайная величина, показывающая количество коллизий в T с ключем x и пусть индикаторная случайная величина

$$C_{xy} = egin{cases} 1, ext{если } h(x) = h(y) \\ 0, ext{иначе} \end{cases}$$

Очевидно, что $E[C_{xy}] = 1/m$ и $C_x = \sum_{y \in T - \{x\}} C_{xy}$. Тогда

$$E[C_x] = E\left[\sum_{y \in T - \{x\}} C_{xy}\right] =$$

$$= \sum_{y \in T - \{x\}} \underbrace{E[C_{xy}]}_{\frac{1}{m}} =$$

$$= \underbrace{\sum_{y \in T - \{x\}} \frac{1}{m}}_{n-1} =$$

$$= \frac{n-1}{m} < \frac{n}{m}$$

3 Конструкция универсального множества

Пусть количество слотов в таблице m – простое число.

Идея: разложить ключ k на r+1 цифр по основанию m, т.е. в промежутке $\{0,1,\ldots,m-1\}$. Тогда $k=< k_0,k_1,\ldots k_r>$, где $0\leqslant k_i\leqslant m$.

Вектор $a=< a_0, a_1, \dots, a_r>$ состоит из элементов, выбранных случайно в промежутке $0,1,\dots,m-1$ независимо друг от друга. Таким образом существует $\prod_{i=0}^r m=m^{r+1}$ вариантов выбора.

Хэш-функция имеет вид:

$$h_a(k) = \left(\sum_{i=0}^r a_i k_i\right) \bmod m$$

Тогда
$$|H| = \{h_a\} = m^{r+1}$$

Теорема: Множество $H = \{h_a\}$ является универсальным.

Пусть $x=< x_0, x_1, \ldots, x_r>$ и $y=< y_0, y_1, \ldots, y_r>$ — два различных ключа из множества U. Т.к. они различны, их разложения должны различаться хотя бы в одной цифре. Не теряя общности, можно предположить, что они различаются в первой цифре (с индексом 0). Необходимо, как часто выполняется условие коллизии:

$$h_a(x) = h_a(y)$$

$$\sum_{i=0}^r a_i x_i \equiv \sum_{i=0}^r a_i y_i \pmod{m}$$

$$\sum_{i=0}^r a_i (x_i - y_i) \equiv 0 \pmod{m}$$

или

$$a_0(x_0 - y_0) + \sum_{i=1}^r a_i x_i \equiv 0 \pmod{m}$$

$$a_0(x_0 - y_0) \equiv -\sum_{i=1}^r a_i x_i \pmod{m}$$

Теорема: пусть m – простое число. Тогда для любого $z\in\mathbb{Z}_m$, такого, что $z\neq 0$, существует единственный элемент $z^{-1}\in\mathbb{Z}_m$, такой, что

$$z \cdot z^{-1} \equiv 1 \pmod{m}$$

Пример для m=7.

| Z | 1 | 2 | 3 | 4 | 5 | 6 |
|----------|---|---|---|---|---|---|
| Z^{-1} | 1 | 4 | 5 | 2 | 3 | 6 |

Рис. 2: Кольцо вычетов \mathbb{Z}_7

Итак,

$$a_0(x_0 - y_0) \equiv -\sum_{i=1}^r a_i x_i(bmodm)$$

из факта $x_0 \neq y_0$ и существования $(x_0 - y_0)^{-1}$

$$a_0 \equiv \left(-\sum_{i=1}^r a_i(x_i - y_i)\right) \cdot (x_0 - y_0)^{-1} (\text{mod } m)$$

Таким образом, для двух различных ключей, для всех возможных вариантов выбора элементов a_1, a_2, \dots, a_r существует только единственный вариант выбора элемента a_0 , который реализует функцию h_a , дающую коллизию.

Т.е. существует m вариантов выбора для a_1, a_2, \ldots, a_r и один для a_0 (по приведенной формуле). Общее число функций h_a , дающих коллизию элементов x и y будет равно

$$m^r \cdot 1 = m^r = \frac{|H|}{m}$$

4 Идеальное хэширование

Задача идеального хэширования возникает тогда, когда возникает необходимость проверять наличие элемента (скажем, слова из словаря) за гарантировано константное время. При этом подразумевается, что набор данных в таблице статичен либо изменяется очень редко.

Задача: для заданного набора из |U|=n ключей создать статическую хэш-таблицу размера m=O(n), такую что операция поиска Search выполнялась бы за $\Theta(1)$ в худшем случае. Таблица должна быть статической, т.е. операции добавления и удаления элементов в ней не поддерживаются.

Идея: сконструировать двухуровневое хэширование с универсальной хэш-функцией на каждом из уровней. Выбрать функции таким образом, чтоб обеспечить отсутствие коллизий на уровне 2.

 $S_1, S_2, ..., S_m$ — хэш-таблицы второго уровня, размер каждой из которых зависит от количества элементов n_i попавших в слот i таблицы T и равен $m=n_i^2$. Каждая таблица S_i обслуживается собственной хэшфункцией h с индексом a_i (вторая колонка таблицы T). Выбор функций происходит на этапе заполнения таблицы (предвычисление).




Рис. 3: Идеальное хэширование

Теорема: пусть H – класс универсальных хэш-функций для таблицы размера $m=n^2$. Тогда для случайной функции $h\in H$ при хэшировании n ключей ожидаемое количество коллизий не превышаеть 1/2.

По свойству универсального множества, вероятность того, что два ключа дадут коллизию для функции h равна $1/m=1/n^2$. Т.к. всего существует C_2^n пар ключей, ожидаемое количество коллизий равно

$$\frac{n!}{2!(n-2)!}\frac{1}{n^2} = \frac{n(n-1)}{2}\frac{1}{n^2} < \frac{1}{2}$$

Следствие: вероятность отсутствия коллизий составляет как минимум 1/2.

Используя неравенство Маркова

$$Pr\{X \geqslant t\} \leqslant E[X]/t$$

рассматривая случай для t=1, получим, что вероятность одной или более коллизий равна не более чем 1/2.

Т.е. множество H как минимум на половину состоит из функций, удовлетворяющих нашим требованиям.

4.1 Анализ размера таблицы

Для первого уровня хэш-таблицы T используется m=n ячеек. Пусть n_i — случайная величина, показывающая количество ключей, попавших в слот i первого уровня таблицы T. Используя n_i^2 слотов для таблицы

второго уровня S_i , ожидаемый общий размер для суммы двух уровней будет равен:

$$E\left[\sum_{i=0}^{m-1}\Theta(n_i^2)\right] = \Theta(n)$$